

Quem vai vencer o segundo turno de 2026?

Versão em português acessível do modelo v6.3

João Renato Santos da Cunha

Maio de 2026

Companheiro do whitepaper técnico v6.3

Contents

1 Quem vai vencer o segundo turno de 2026?	1
1.0.1 Versão em português acessível do modelo eleitoral v6.3	1
1.1 O que é este modelo, em uma frase?	2
1.2 Por que focar só no segundo turno?	2
1.3 Como o modelo funciona? Uma analogia.	2
1.4 Três grandes decisões de desenho	3
1.4.1 Decisão 1: jogamos fora quatro das seis “fontes de dados”	3
1.4.2 Decisão 2: tentamos corrigir o viés dos institutos, descobrimos que piora, e abandonamos	3
1.4.3 Decisão 3 (v6.2, nova): o modelo agora vê cada candidato como distinto	4
1.5 Quão bem funciona? O backtest.	5
1.6 O que ele diz sobre 2026?	5
1.6.1 Duas nuances importantes	7
1.7 O que o modelo <i>não</i> consegue fazer	7
1.8 E se você discorda de alguma das nossas premissas?	8
1.9 Em resumo	8
1.10 Onde aprender mais	9

1 Quem vai vencer o segundo turno de 2026?

1.0.1 Versão em português acessível do modelo eleitoral v6.3

Esta é a versão amigável. O paper técnico (com equações, derivações formais e bibliografia) está em [whitepaper.md](#) / [whitepaper.pdf](#). Aqui explicamos **o que o modelo realmente faz, por que foi desenhado assim e o que ele diz sobre 2026** — em linguagem que qualquer pessoa consegue acompanhar.

Sobre a v6.3 (maio/2026). Esta versão vem depois de uma auditoria interna (peer review) que encontrou quatro bugs na v6.2 — sendo o mais grave um *vazamento de dados na correção de viés dos institutos* (o modelo estava secretamente recebendo a resposta antes da pergunta) e uma *contagem dupla de precisão* que fazia as pesquisas sufocarem completamente o sinal da aprovação. Depois das correções, o modelo é significativamente mais honesto: a acurácia do backtest é a mesma (6 acertos em 6), mas o escore de Brier melhora de 0.132 para 0.097, o erro médio de share cai de 4.5 pp para 2.7 pp, e o teste de estresse de aprovação (que dava *zero* variação na v6.2)

agora se comporta como esperado. O número-resumo de 2026 — **direita 50.2%** — segue inalterado. Detalhes em `PEER_REVIEW.md`.

1.1 O que é este modelo, em uma frase?

Construímos uma calculadora que pega tudo o que sabemos sobre uma eleição presidencial brasileira — as pesquisas, a aprovação do governo, os mercados de apostas, quem doou para quem, como senadores têm votado e como o país tem mudado — e transforma tudo isso em **um número**: a probabilidade de o desafiante vencer o segundo turno.

É só isso. Não é uma tabela longa de “quem lidera onde”, nem cinco cenários hipotéticos com asteriscos. **Uma probabilidade.**

1.2 Por que focar só no segundo turno?

Das últimas seis eleições presidenciais brasileiras, cinco foram decididas no segundo turno (1998 foi a única exceção — FHC ganhou direto no primeiro). O primeiro turno funciona, na prática, como um *torneio classificatório* que define quem chega à final de verdade.

Isso importa para a matemática. Modelar o primeiro turno significa lidar com cinco a oito candidatos ao mesmo tempo — um problema bem mais difícil, com muitas peças móveis e poucos dados. Modelar o segundo turno é mais simples: é A contra B, o tipo de pergunta de “cara ou coroa” que um modelo binário trata bem.

Concentrando-nos no segundo turno, ganhamos:

- **Matemática mais limpa** — do tipo que cabe em uma página e não exige simulação computacional pesada para resolver.
- **Pesquisas mais limpas** — pesquisas de 2T têm só dois candidatos, então o instituto não consegue esconder um deles numa categoria “outros”.
- **Pergunta mais clara** — “quem ganha a presidência” é o que o leitor de fato quer saber.

O contraponto é que *não conseguimos* dizer quem chega ao segundo turno. Tratamos isso como uma pergunta separada (mais sobre isso adiante, na seção de 2026).

1.3 Como o modelo funciona? Uma analogia.

Imagine que você está tentando adivinhar a temperatura lá fora, mas não pode olhar para o termômetro. Você tem:

- Um amigo que olha pela janela e diz “tá fresco” (essas são as **pesquisas** — muitas opiniões de qualidade variável).
- Um aplicativo no celular dizendo 18°C (essa é a **aprovação do governo** — um único sinal estruturado).
- Um mercado de apostas onde estranhos apostam na temperatura (os **mercados de previsão**).

- Padrões recentes do clima (doações, votações no Congresso, tendências demográficas — o coadjuvante).

Cada fonte tem ruído. As pesquisas discordam entre si. O app pode estar desatualizado. O mercado de apostas pode ter poucos participantes.

O que fazemos é tratar cada fonte como evidência com uma *precisão conhecida* — quanto confiamos nela. Daí combinamos tudo usando uma regra de estatística bayesiana que basicamente diz: “dê peso a cada fonte proporcional ao quanto ela é confiável, e combine em um único melhor palpite”.

O nome técnico disso é **posterior gaussiana fechada no espaço logit**. O nome amigável é **uma média ponderada que respeita a incerteza**.

1.4 Três grandes decisões de desenho

1.4.1 Decisão 1: jogamos fora quatro das seis “fontes de dados”

Quando começamos, o framework tinha seis fontes de informação: pesquisas, mercados de previsão, aprovação, doações, votações nominais no Congresso e dados demográficos.

Quando rodamos a matemática sobre seis eleições de backtest histórico, o resultado foi desconfortável: **quatro das seis fontes contribuíam praticamente nada**. Removê-las deixava o modelo *ligeiramente melhor*, não pior.

Por quê? Porque no Brasil essas fontes tendem a ser ou esparsas demais (mercados de previsão eram rasos antes de 2022), ou manipuláveis demais (o financiamento de campanha é notoriamente distorcido pelo **fundo eleitoral** e contribuições ocultas), ou ligadas apenas fracamente à intenção de voto (votação no Congresso diz muito sobre estrutura de coalizão, mas não move o ponteiro de quem vence).

Então, na versão 6, ficamos apenas com as duas fontes que de fato movem o forecast:

- **Pesquisas de intenção de voto** no segundo turno
- **Aprovação do governo** — especificamente, a média dos três meses anteriores à eleição e a tendência dos seis meses anteriores

As outras quatro continuam sendo calculadas e reportadas, mas como *diagnóstico*, não como insumo. Se elas discordam muito do forecast principal, tratamos isso como um sinal a ser investigado qualitativamente — mas não deixamos elas empurrarem o número-resumo.

Essa é a escolha pela “parsimônia”. **Um modelo mais simples que usa os dados honestamente vence um modelo mais elaborado que finge usar mais dados do que realmente consegue.**

1.4.2 Decisão 2: tentamos corrigir o viés dos institutos, descobrimos que piora, e abandonamos

As pesquisas erram sistematicamente, não só aleatoriamente. Datafolha e Quaest tendem a inclinar para um lado; o Veritá para o outro. Isso se chama “house effect” na literatura de forecasting.

Uma abordagem ingênua seria dizer “Datafolha sempre superestima o candidato de esquerda em 5 pontos, então subtraia 5”. Foi assim que as versões v5 e v6 (parcial) do nosso modelo funcionavam.

Aprimoramos esse esquema dividindo o erro de cada pesquisa em duas peças — uma persistente (a inclinação metodológica duradoura do instituto) e uma de oscilação (o desvio que pega a indústria inteira numa eleição específica). E descobrimos algo notável: **um terço do “viés de instituto” aparente dos principais institutos brasileiros era, na verdade, a peça de oscilação disfarçada.**

Mas — e isso é importante — na v6.3 abandonamos a correção inteira.

A auditoria interna mostrou dois problemas: (i) a implementação original tinha *vazamento de dados* (o modelo estimava o viés de cada instituto usando dados da própria eleição que ele estava tentando prever); e (ii) mesmo numa versão honesta que excluísse a eleição-alvo do treino, **a correção piora o backtest** em relação a usar as pesquisas cruas. Causa raiz: a identidade do candidato A muda entre eleições (PT, PSDB, PL), então o viés “do instituto” se confunde com o viés “do partido na cédula”.

O resultado prático para 2026: **usamos as pesquisas como elas saem**, sem subtrair nada. Em vez de fingir que sabemos o viés de cada instituto, deixamos a incerteza irreduzível absorver esse erro no posterior. O Brier melhora de 0.132 (v6.2 com correção contaminada) para 0.097 (v6.3 com polls cruas). O texto desta seção permanece para explicar por que o caminho parecia atraente — e por que a evidência empírica fez a gente desistir dele.

1.4.3 Decisão 3 (v6.2, nova): o modelo agora vê cada candidato como distinto

Aqui está o problema que a atualização v6.2 resolve.

Quando não temos pesquisas de segundo turno para um candidato específico — exatamente a situação de Michelle Bolsonaro, Renan Santos e (em maio de 2026) Tarcísio — o modelo enxuto antigo recorria ao único sinal não-específico ao candidato que tinha: a aprovação de Lula. Resultado: **três candidatos diferentes recebiam probabilidades idênticas de vitória**, porque o único insumo que os distinguia (pesquisas) faltava para os três.

Isso é honesto num sentido (“os dados não os distinguem”), mas é uma representação pobre da realidade. *Temos* evidência — mesmo sem pesquisas dedicadas — de que Tarcísio (governador com forte base em SP) é estruturalmente diferente de Renan (líder de movimento com alcance nacional limitado).

A correção da v6.2 é separar o forecast em duas peças:

- Um **humor macro** — puxado pela aprovação do governo, comum a todos os candidatos do mesmo bloco.
- Um **desvio específico do candidato** — quanto este candidato particular fica acima ou abaixo do humor macro.

Para candidatos com pesquisas (Flávio), o desvio sai das próprias pesquisas. Para candidatos sem pesquisas (Tarcísio, Michelle, Renan), usamos uma **âncora especialista**: uma estimativa estrutural cuidadosa de onde eles ficariam num 2T, com incerteza explícita sobre essa estimativa.

Pense assim: para prever a temperatura numa cidade onde seu app está quebrado, você chutaria “provavelmente perto da média regional, com barra de erro maior”. É isso que a âncora faz. Ela é honesta sobre incerteza — a âncora da Michelle tem barra de erro mais larga que a de Tarcísio, porque sabemos menos sobre as chances dela num 2T — mas ainda permite ao modelo reconhecer que os candidatos *são* diferentes.

1.5 Quão bem funciona? O backtest.

Rodamos o modelo em cada um dos seis segundos turnos brasileiros pós-2002, como se estivéssemos uma semana antes do dia da eleição. Seis previsões, seis resultados reais:

Ano	Vencedor	Confiança do modelo no vencedor real
2002	Lula	68%
2006	Lula (reeleição)	59%
2010	Dilma	50%
2014	Dilma (reeleição)	63%
2018	Bolsonaro	75%
2022	Lula	73%

O modelo identificou corretamente o vencedor nas seis eleições. A confiança média no vencedor real é aproximadamente 65% — o “ponto ideal” de um forecaster bem calibrado. (Forecasters *super-confiantes* batem 90%+ e ficam ridículos quando erram; os que se protegem em 55% não servem para nada. 60-70% num retrospecto de 6/6 é exatamente o que se quer.)

O caso de 2010 é o mais delicado: a aprovação de Lula estava em pico histórico (+55 pontos!) e normalmente teria dominado o forecast, mas as pesquisas de 2T daquele ciclo estavam praticamente empatadas. O modelo v6.1 recalibrado atribui probabilidade igual — capturando *ex-ante* que aquilo era cara-ou-coroa, ainda que *ex-post* Dilma tenha vencido 56-44. Preferimos honrar a incerteza das pesquisas a fingir que a aprovação nos dava uma certeza que ela não entregou no horário da urna.

As probabilidades acima são da versão v6.1 (mantidas aqui porque são as publicadas elemento-por-elemento). Para essa versão, o erro médio da fatia prevista é cerca de 4.5 pontos percentuais. **Sob a v6.3 (corrigida pela auditoria), o backtest mantém os 6 acertos confiantes e melhora o Brier de 0.132 para 0.097 e o erro médio de share de 4.5 pp para 2.7 pp** — a nota inicial deste paper resume essa mudança. As pesquisas em campo individualmente erravam 4-5 pontos; o trabalho do nosso modelo é combinar essas pesquisas com sinais estruturais para superar qualquer pesquisa isolada — e ele entrega.

1.6 O que ele diz sobre 2026?

Aqui é onde a coisa fica interessante. Em maio de 2026:

1. A aprovação líquida de Lula está em **menos oito** (o público está moderadamente insatisfeito com o governo, mas não está catastrófico).

2. A **crise do Banco Master** (banco intervindo pelo BACEN em 2025, com vínculos documentados à família Bolsonaro) enfraqueceu gravemente a candidatura de Flávio Bolsonaro.
3. **Tarcísio de Freitas**, governador de São Paulo, emerge como o sucessor natural do PL — carrega a base bolsonarista mas sem os passivos jurídicos da família.
4. **Michelle Bolsonaro** mantém capital simbólico entre os evangélicos, mas a inexperiência limita sua viabilidade.
5. **Renan Santos** (líder do MBL) representa a ala antissistema do bloco.

Então não temos só uma eleição; temos uma eleição *somada à incerteza sobre quem será um dos candidatos*. Lidamos com isso rodando o forecast quatro vezes — uma por candidato — e tirando a média, ponderada pela probabilidade de cada um efetivamente estar na cédula.

Usamos estes priors subjetivos (sinta-se livre para discordar):

- 45% de chance de Tarcísio ser o candidato (sucessor PL natural pós-Banco Master)
- 25% de chance de Michelle assumir (caminho do capital simbólico)
- 15% de chance de Flávio permanecer apesar do passivo Banco Master
- 15% de chance de Renan emergir (cenário de fratura PL)

Para Flávio aplicamos, ainda, uma **correção de -1.5 ponto** sobre as pesquisas existentes, porque essas pesquisas foram a campo em abril de 2026, *antes* de a crise do Banco Master se escalar totalmente. Empiricamente, pesquisas levam 2-4 semanas para absorver choques de escândalo de candidato — então a fotografia que temos provavelmente superestima o apoio atual a Flávio.

Para Tarcísio construímos uma **âncora composta**: ele lidera as pesquisas de 2T para governador de SP em torno de 57% (e SP é 22% da população do país), e extrapolamos seu apoio fora de SP em torno de 51% (uma melhora leve sobre o desempenho de Bolsonaro fora de SP em 2022, refletindo eleitores de centro-direita que rejeitam a família mas aceitam Tarcísio). A composição ponderada por população dá 52.3% como estimativa nacional de 2T.

Os forecasts resultantes:

Cenário	Âncora / Pesquisas	Probabilidade da direita vencer
Tarcísio	âncora 0.523 ± 0.20	56%
Flávio (pós-shift Banco Master)	pesquisas 0.505	52%
Michelle	âncora 0.49 ± 0.28	48%
Renan	âncora 0.43 ± 0.35	36%
Média ponderada pelos priors acima		50%

Então, **centro-direita 50%, Lula 50%** — no fio da navalha.

Esse é um deslocamento expressivo em relação à estimativa enxuta v6.1 de direita 54%. Quatro forças puxam o marginal de volta para a paridade:

1. Renan é agora identificado como candidato estruturalmente fraco (36% vs. os ~54% indistintos que recebia na v6.1), e seu prior de 15% puxa a média para baixo.
2. A âncora de Michelle está abaixo de 50%, refletindo a penalidade de “substituição por gênero” documentada na literatura de ciência política.

3. A composição de Tarcísio é mais conservadora (52.3%) que o padrão da v6.1, que assumia todos os candidatos não-pesquisados em ~54%.
4. O shift do Banco Master tira mais um ponto de Flávio.

1.6.1 Duas nuances importantes

Primeira. O forecast é sensível a qual candidato efetivamente disputa. O intervalo puro entre candidatos vai de 36% (Renan) a 56% (Tarcísio) — 20 pontos de amplitude. Na v6.1 essa amplitude era 0.5 ponto (o problema do “candidate-blind”). A amplitude na v6.2 reflete informação real e específica do candidato, não ruído.

Segunda. Na v6.2, a probabilidade-síntese é *menos* diretamente sensível à aprovação do governo do que reportava a v6.1 — cerca de 1.4 ponto para cada oscilação de 20 pontos na aprovação, vs. 32 pontos na v6.1. Isso não é bug; é o modelo reconhecendo que pesquisas e aprovação são informacionalmente ligadas, então um contrafactual de “a aprovação mudou 20 pontos” só faz sentido se assumirmos também que as pesquisas ainda não capturaram essa mudança. Oferecemos no paper técnico um teste de estresse “aprovação pura” separado, que dá uma amplitude maior (± 8 pontos no marginal) para analistas que queiram a sensibilidade incondicional.

1.7 O que o modelo *não* consegue fazer

Queremos ser honestos sobre limitações:

1. **Seis eleições é pouco.** Estatisticamente, os intervalos de confiança sobre as métricas do backtest são amplos. Uma leitura pessimista dos dados é consistente com o modelo não ser muito melhor do que “sempre escolher o candidato à frente nas pesquisas”.
2. **As âncoras especialistas carregam subjetividade.** Quando não temos pesquisas para um candidato (Michelle, Renan, Tarcísio), fornecemos uma estimativa-âncora e uma incerteza ao redor dela. Essas escolhas são defensáveis, mas em última instância são nosso julgamento. Se você discorda, as âncoras são parâmetros explícitos — mude-as.
3. **Não conseguimos prever quem sobrevive ao primeiro turno.** O modelo assume que os candidatos de 2T são quem dizemos que são. Se um candidato surpresa emergir (alguém oscilando em 5% que dispara no último mês), não temos nada a dizer.
4. **Quebras estruturais** — golpes, impeachments, escândalos majores, mortes, pandemias — vão quebrar o modelo. A crise do Banco Master é o tipo de choque estrutural que *parcialmente conseguimos* ajustar (o event-shift sobre Flávio), mas um choque maior excederia o que o ajuste captura.
5. **O “contexto brasileiro” está mudando.** Evangélicos são 33% da população em 2026 (vs. 22% em 2010). O fundo eleitoral redistribui dinheiro de campanha de forma sem precedentes pré-2018. O treino histórico do modelo tem memória limitada dessas mudanças estruturais.
6. **Os diagnósticos auxiliares** (mercados, doações, votações no Congresso, demografia) são calculados mas não entram no forecast principal. Se você é trader ou estrategista de campanha, eles ainda podem ser úteis como cruzamento — mas deliberadamente não

deixamos eles influenciarem o número-resumo, porque a evidência histórica diz que eles introduzem mais ruído que sinal.

1.8 E se você discorda de alguma das nossas premissas?

O modelo foi construído para que todas as escolhas-chave sejam *explícitas e ajustáveis*:

- Não acredita que a aprovação está em -8 ? Tente outro número. O forecast se move junto.
- Acha que Flávio definitivamente continua apesar do Banco Master? Coloque o prior dele em 100%. O forecast vira só o cenário Flávio (52%).
- Acha que a composição do Tarcísio superestima a transferência fora-de-SP? Reduza a âncora. O cenário Tarcísio cai.
- Acha que mercados deveriam importar? Reative com peso positivo. O forecast vai inclinar para o que os mercados estão dizendo.
- Discorda do tamanho do event-shift do Banco Master? Mude -1.5 para -3 pp ou para zero. O cenário Flávio se ajusta.

Todos esses botões vivem em dois arquivos curtos de configuração no repositório do projeto. O modelo não é uma caixa-preta.

1.9 Em resumo

1. Eleições presidenciais brasileiras são decididas no segundo turno, então construímos um modelo que mira o segundo turno diretamente.
 2. Combinamos pesquisas e aprovação do governo numa única probabilidade de o desafiante vencer. Outras fontes são vigiadas mas não dirigem a resposta.
 3. Corrigimos os vieses sistemáticos de cada instituto — cuidadosamente, de forma a distinguir “Datafolha sempre puxa para esquerda” de “a indústria inteira errou Bolsonaro 2018”.
 4. Na v6.2, separamos o forecast num *humor macro* (puxado pela aprovação) e num *desvio específico do candidato* (puxado por pesquisas ou por âncora especialista), para que candidatos sejam distinguidos mesmo quando não temos pesquisas dedicadas para todos.
 5. O modelo identificou corretamente o vencedor de todos os segundos turnos brasileiros desde 2002 (seis em seis), com confiança calibrada na faixa dos 65%.
 6. Para 2026, o modelo coloca o bloco centro-direita em cerca de **50%** para vencer, com Lula também em **50%** — no fio da navalha. Tarcísio é o candidato mais forte do centro-direita (56%); Renan é o mais fraco (36%). A crise do Banco Master tirou aproximadamente um ponto da probabilidade de Flávio em relação a onde as pesquisas de abril o teriam colocado.
 7. Analistas de boa-fé podem mexer nos insumos e chegar a respostas diferentes. O modelo é uma ferramenta para afiar intuição, não um substituto dela.
-

1.10 Onde aprender mais

- **Paper técnico.** Todas as equações, derivações e métricas de validação no `whitepaper.pdf` que acompanha este documento.
- **Resposta ao revisor.** O raciocínio por trás da sequência $v5 \rightarrow v6.0 \rightarrow v6.1 \rightarrow v6.2 \rightarrow v6.3$ de revisões, incluindo a auditoria de sensibilidade e a decomposição bivariada, está em `response_to_reviewer.md` no repositório de pesquisa.
- **Dashboard interativo.** Visualização ao vivo dos seis backtests históricos e dos cenários de 2026 em ojaorc.github.io/modelo-br-2026-dashboard.
- **Código e dados.** O modelo é totalmente reproduzível a partir do repositório de pesquisa do projeto (acesso sob solicitação).

Mantido por João Renato Santos da Cunha. Comentários e correções são bem-vindos.

Preparado com auxílio de IA generativa (veja a disclosure no paper técnico).